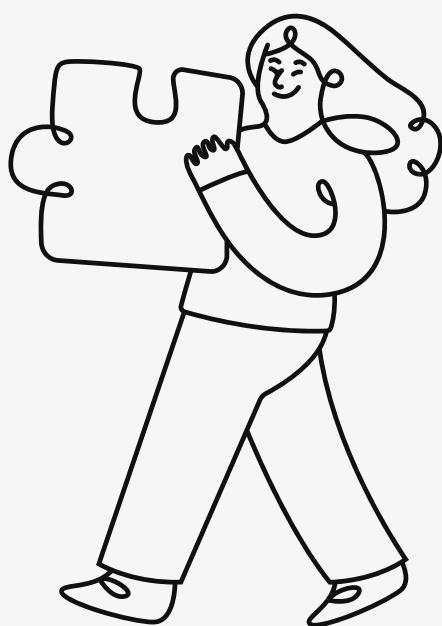


Variables Dependientes e Independientes



Juan Medina
Daniel Montañez
Sergio Ruiz
Daniel Soracipa





Contenido



- ❖ ¿Por qué es esto importante?
 - ❖ Definiciones Clave: Independiente vs. Dependiente
 - ❖ La Relación Fundamental: $y = f(x)$
 - ❖ Aplicación en Computación Visual: Inputs y Outputs
 - ❖ Ejemplos Prácticos en Tareas Visuales
 - ❖ Más Allá de lo Simple: Múltiples Variables
- 

Contenido



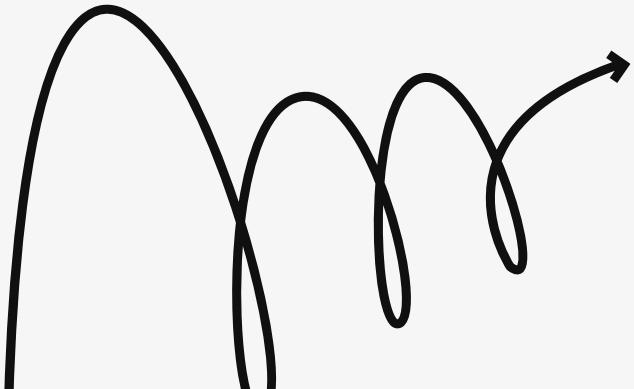
- Representación Gráfica de Modelos
- Errores Comunes y Buenas Prácticas



¿Por Qué Es Esto Importante?



- Definir correctamente qué es entrada (independiente) y qué es salida(dependiente) determina:
 - Cómo formulamos el problema.
 - Qué datos necesitamos.
 - Cómo entrenamos el modelo.
 - Cómo evaluamos su rendimiento.



Definiciones

Definición: Variable Independiente (X)

Es el dato, característica o condición que el modelo recibe como entrada.

- Es lo que observamos, medimos, controlamos o proporcionamos al modelo.
- Se presume que influye o causa un cambio en otra variable.
- El modelo no la modifica, la usa "tal cual".



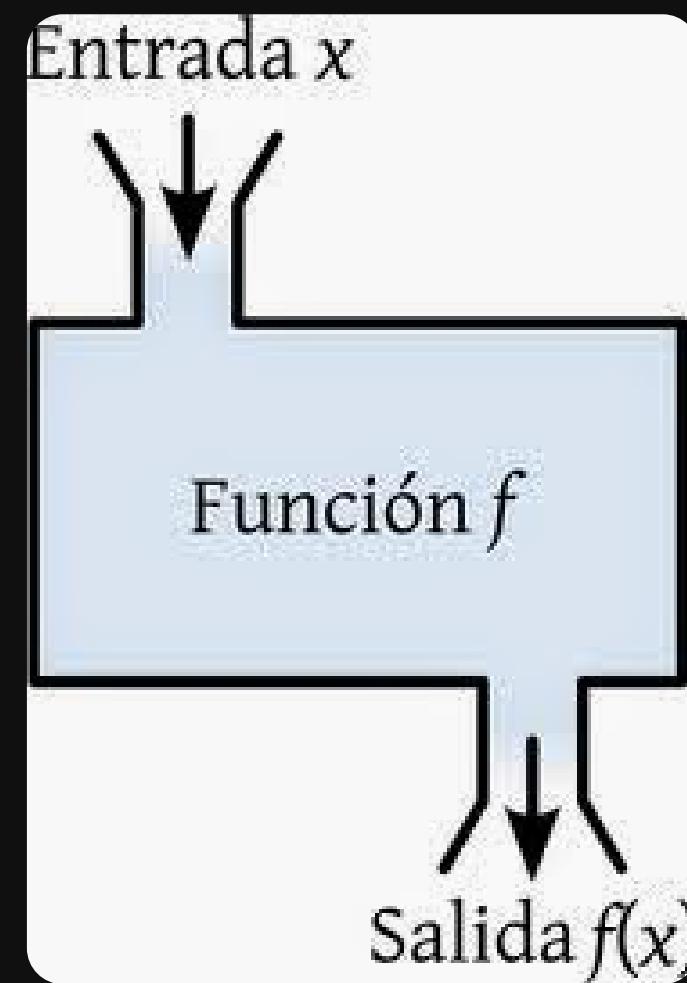
Variable Dependiente (Y)

Es el dato, resultado o predicción que el modelo intenta producir, estimar o clasificar.

- Es lo que queremos predecir, entender o generar.
- Su valor depende (o se espera que dependa) de la variable independiente.
- Es el resultado del procesamiento del modelo.



La Relación Fundamental: $y=f(x)$



x: Variable(s) Independiente(s) (Input)

y: Variable(s) Dependiente(s) (Output)

f: La función, el modelo, la "caja negra" que transforma x en y

El objetivo de muchos modelos computacionales (especialmente en Machine Learning) es encontrar o aproximar esta función f

En Computación Visual: ¿Qué es X?

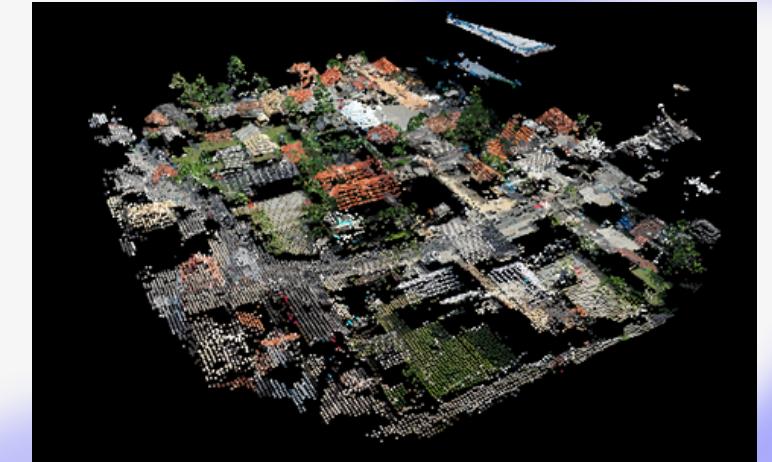
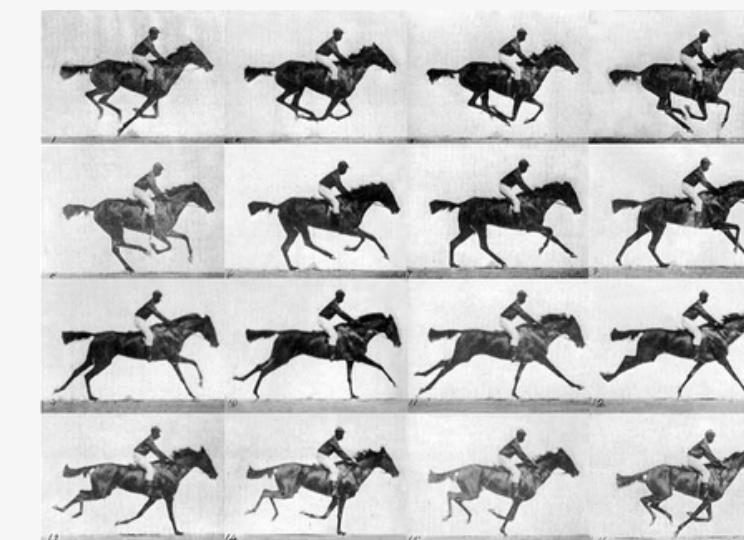
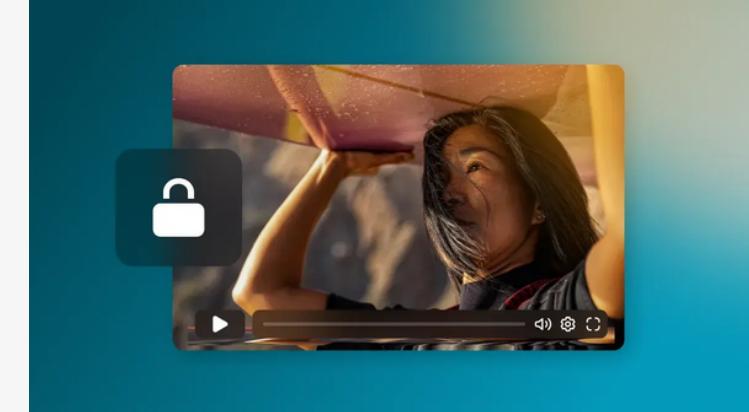
"En nuestro campo, la variable independiente (X) suele ser información visual:

- Imágenes estáticas: (JPG, PNG, etc.)
- Ej: Foto de un gato, radiografía, imagen satelital.
- Secuencias de video: (Colección de frames)
- Ej: Grabación de una cámara de seguridad, video de un dron.

Fotogramas, nube de puntos, videos



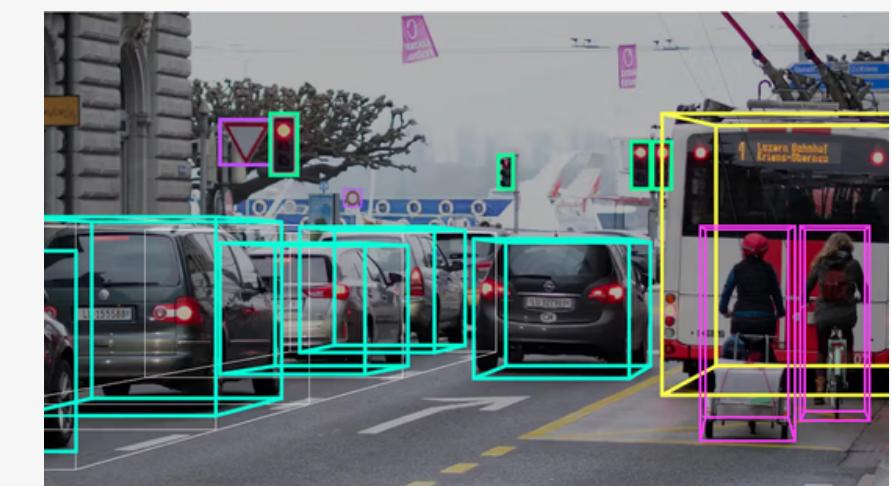
- Ej: Escaneo de un LiDAR, datos de una Kinect.
- A veces, datos adicionales junto con la imagen:
- Metadatos (hora, ubicación GPS).
- Condiciones de iluminación, ángulo de la cámara.



En Computación Visual: ¿Qué es Y?

La variable dependiente (Y) es lo que queremos que el modelo nos diga sobre el input visual:"

Bounding box



Una etiqueta de clase: (Clasificación)

Ej: "gato", "perro", "semáforo en rojo", "tumor benigno".

Coordenadas y clase de objetos: (Detección de Objetos)

Ej: $[(x_1,y_1,x_2,y_2), \text{"coche"}], [(x_3,y_3,x_4,y_4), \text{"peatón"}]$.

Una máscara de segmentación: (Segmentación Semántica/Instancias)

Ej: Qué píxeles pertenecen a la carretera, qué píxeles a un edificio.

Una identidad o características: (Reconocimiento Facial, Re-identificación)

Ej: "Persona A", vector de características faciales.

Un mapa de profundidad o una nueva imagen: (Estimación de Profundidad, Generación de Imágenes)

Ej: Mapa que indica qué tan lejos está cada píxel, imagen estilizada.

Ejemplo Visual 1: Clasificación

Clasificación de Imágenes

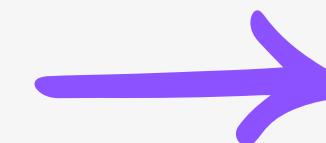
Representación

Imagen



Tarea: Dada una imagen, asignarle una etiqueta de una lista predefinida.

- **Imagen de entrada (X):** Una foto de un semáforo.
- **Salida deseada (Y):** La etiqueta "semáforo" (o "semáforo en rojo", "semáforo en verde").
(Mostrar la etiqueta al lado o debajo)



Etiqueta
"SEMAFORO"



Detección de Objetos

Tarea: Localizar y clasificar múltiples objetos en una imagen.

- Localizar y clasificar múltiples objetos en una imagen.
- Imagen de entrada (X): Una foto de una calle con coches y peatones. (Mostrar la imagen)



- Salida deseada (Y): Una lista de: [Coordenadas del Bounding Box + Etiqueta de Clase] para cada objeto.
- Ej: [(x1,y1,w1,h1), "coche"], [(x2,y2,w2,h2), "peatón"]



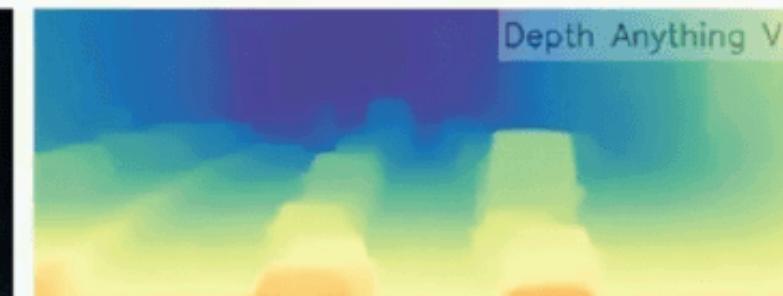
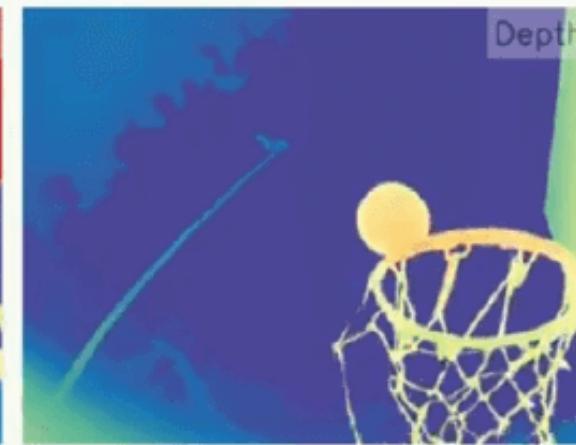
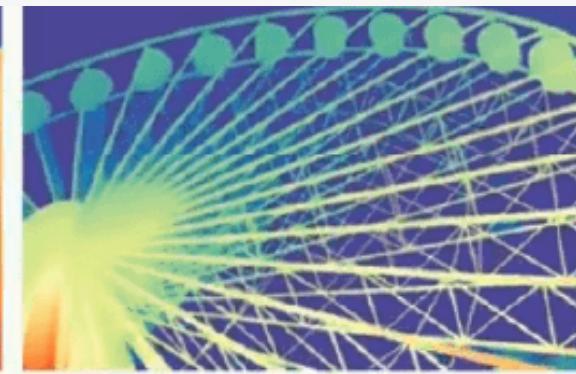
Segmentación Semántica

Tarea: Asignar una etiqueta de clase a cada píxel de la imagen.



Estimación de Profundidad

Tarea: Estimar la distancia de cada punto de la escena a la cámara.



**multiples
variables**

Múltiples Variables Independientes

- El modelo puede usar varias fuentes de información.
- Ejemplo: Imagen + Datos de un sensor LiDAR + Condiciones de iluminación (como texto o números).
- $y=f(x_1, x_2, \dots, x_n)$

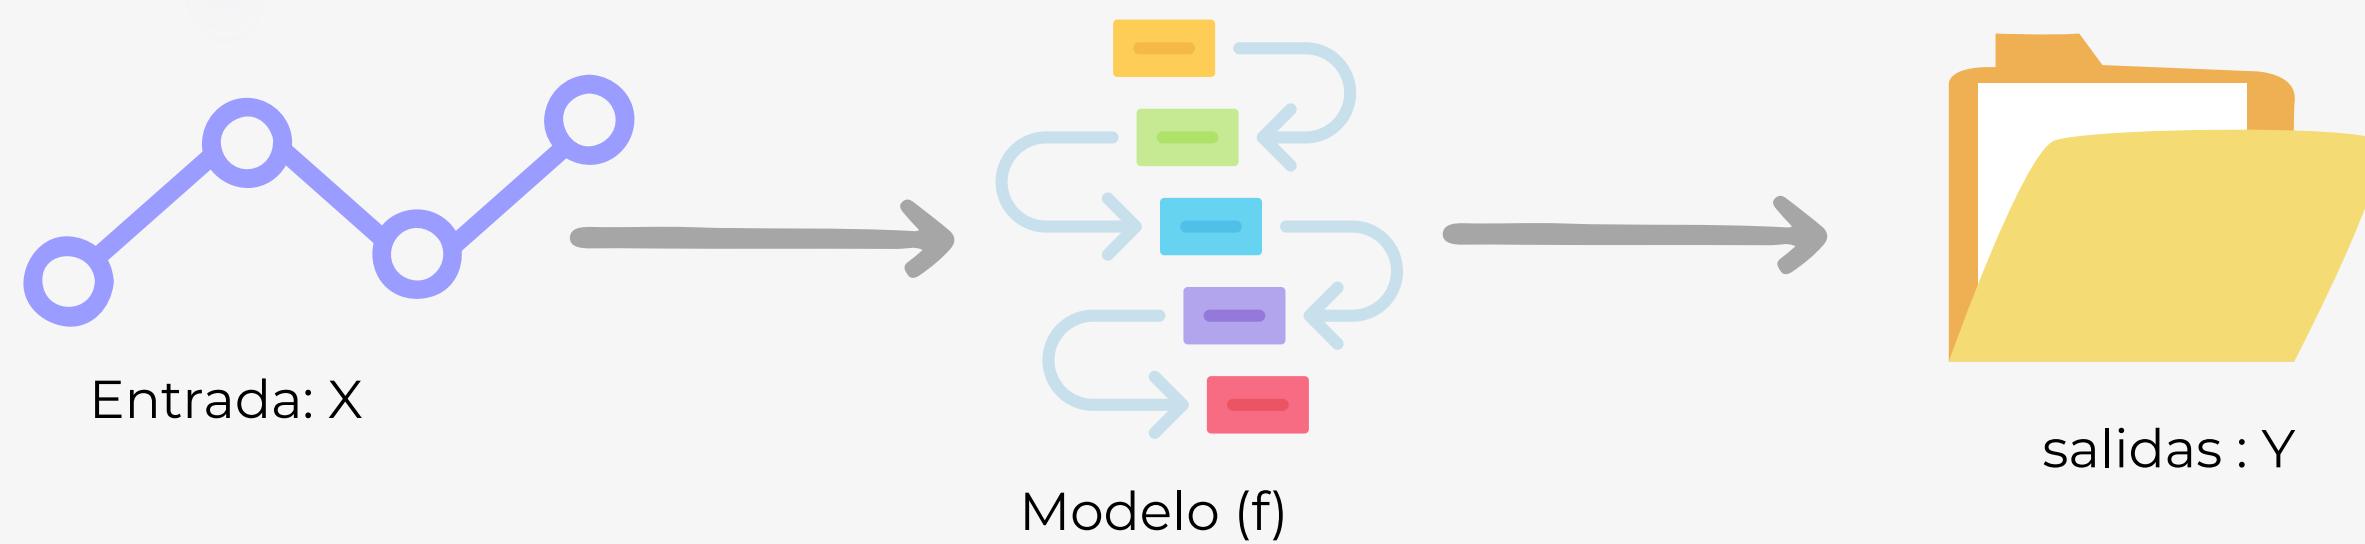


Múltiples Variables Dependientes

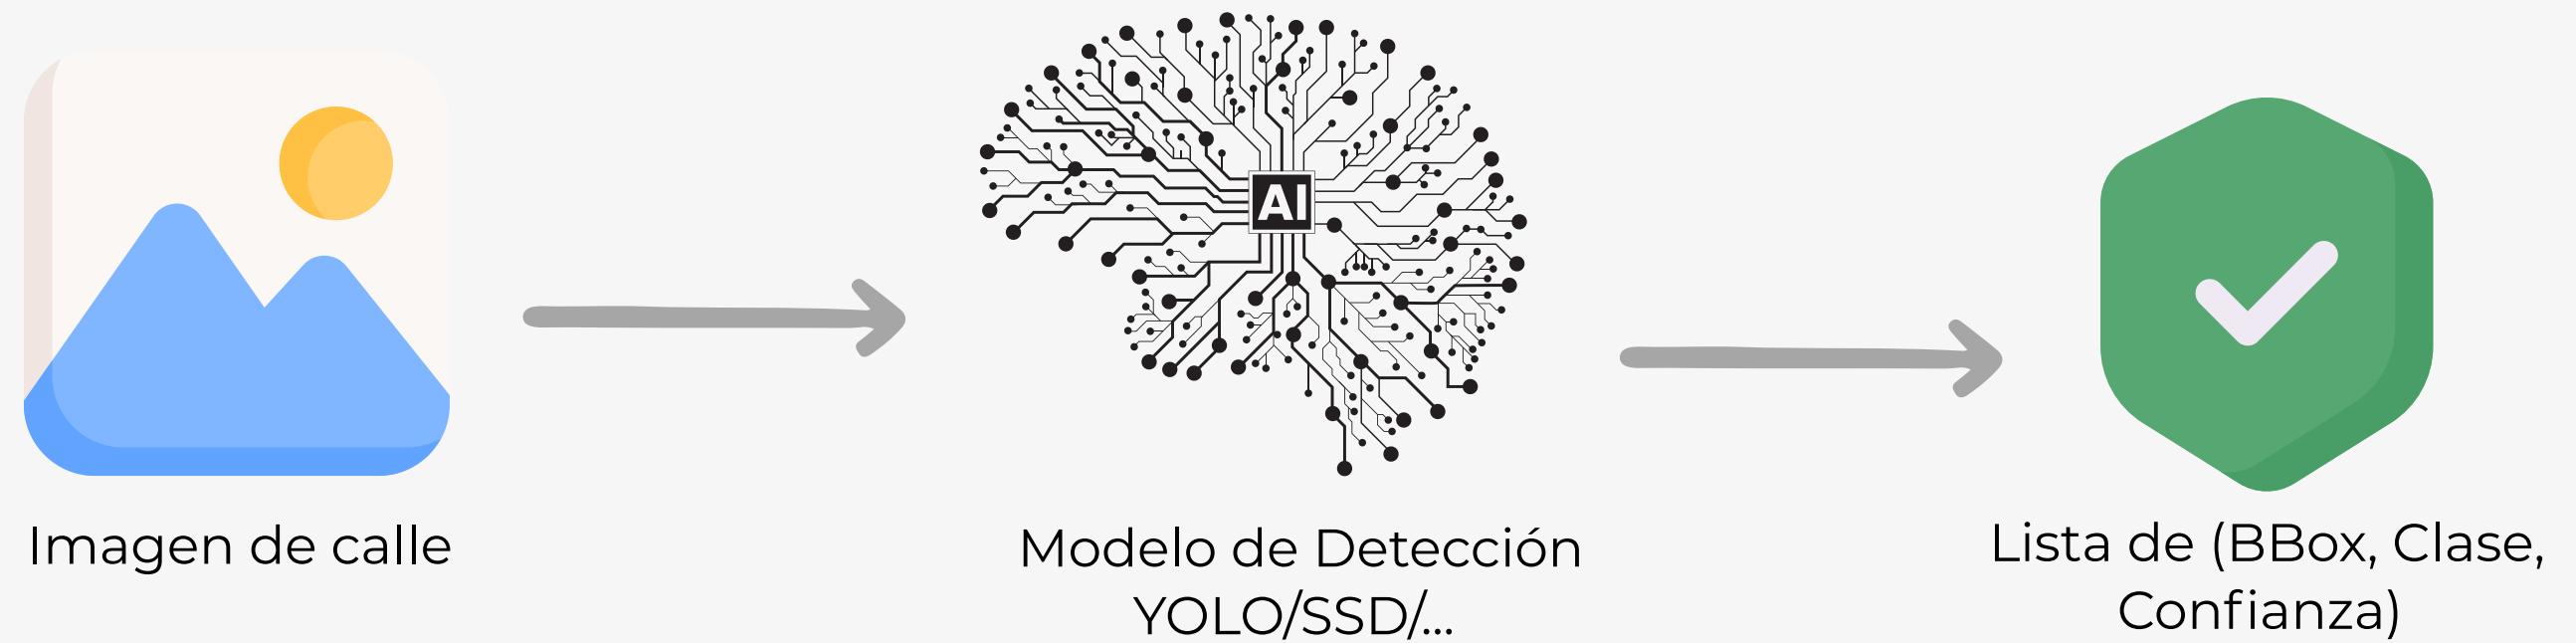
- El modelo puede predecir varias cosas a la vez.
- Ejemplo (Detección de Objetos): Coordenadas del objeto (Y_1) + Clase del objeto (Y_2) + nivel de confianza de la detección (Y_3)
- $(y_1, y_2, \dots, y_m) = f(x)$

Representación Gráfica de Modelos

Diagrama de Caja Simple (general):



Ejemplo



Erros Comunes y Buenas Prácticas

$$\begin{aligned} dx &= \left(x^2 \ln x + \frac{x}{2} - x^4 - \frac{x^4}{4} \right) dx \\ &= 0 \left(\frac{2}{7} x^2 + \frac{x^2}{2} - \frac{3}{10} x^5 \right) dx \\ &= \frac{33}{140} x^2 dx \end{aligned}$$

Errores Comunes:



Confundir correlación
con causalidad:

No alinear X e Y
correctamente en el
dataset:

Definir Y
de forma poco útil

La imagen NO ES la
etiqueta

Buenas Prácticas



Ser específico

Verificar la calidad de los datos

Pensar en el objetivo final:

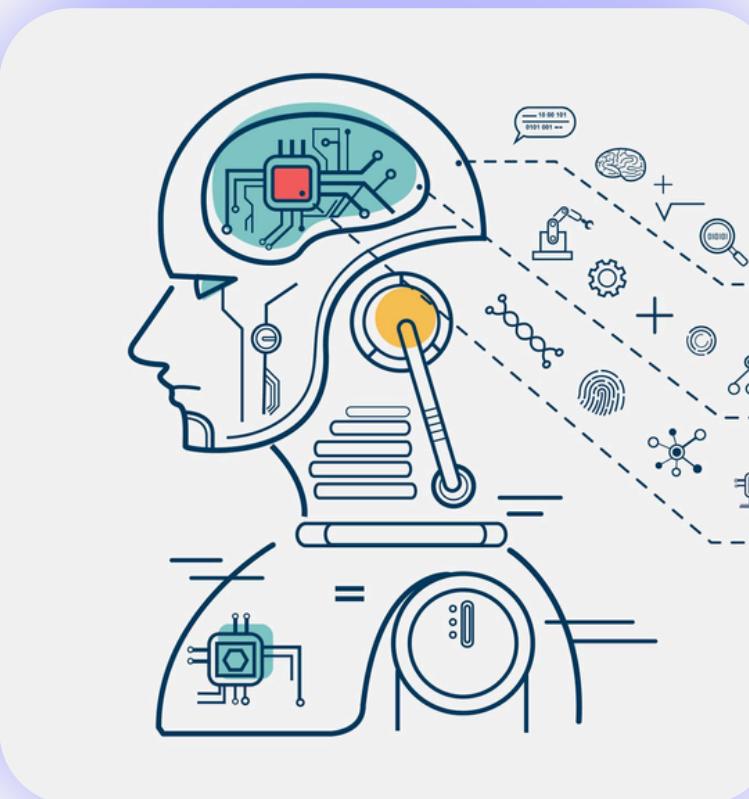
La Importancia de una Buena Definición para Entrenar Modelos

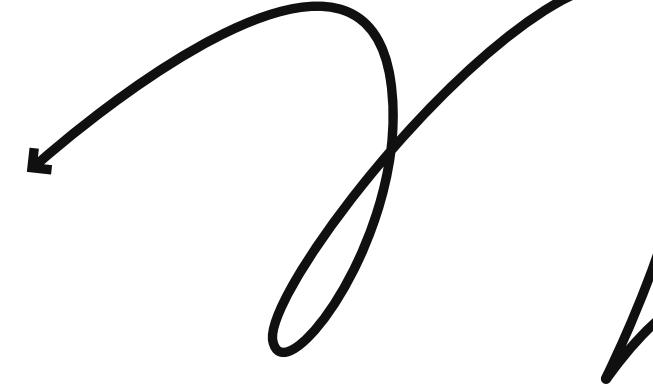
El proceso de 'entrenamiento' de un modelo de Machine Learning se basa en mostrarle muchos ejemplos de pares (X, Y).

El modelo ajusta sus parámetros internos para que, dado un X , su predicción Y_{pred} se parezca lo más posible al Y_{real} (la etiqueta o valor verdadero).

Si X o Y están mal definidos o son ambiguos:

- El modelo no sabrá qué aprender.
- Las métricas de error no tendrán sentido.
- El modelo resultante será inútil o poco fiable.
- "Ejemplo de mala definición:"
 - X : Imagen de un animal.
 - Y : "Es bonito" (Subjetivo, difícil de medir y aprender consistentemente).
 - Resultado: Modelo inútil.





GRACIAS

